Capitolo 1

Introduzione

1.1 Tipi di ragionamenti

• Ragionamento Deduttivo: da ricondurre ad Aristotele (384 a.C.-322a.C.). Da una regola e da un caso ottengo un risultato. È il ragionamento che permette la dimostrazione dei teoremi, ed è stata la base dei AI degli anni '90.

Esempio

REGOLA: "Tutti gli uomini sono mortali."

CASO: "Socrate è un uomo." RISULTATO: "Socrate è mortale."

• Ragionamento Induttivo: da ricondurre a Bacon (1561-1626).

Avviene un'operazione di generalizzazione. Si hanno le premesse, casi particolari, che danno valenza a una certa regola, che è appunto una generalizzazione dei casi particolari. Di tale valenza non ne siamo sicuri a priori e deve essere dimostrata matematicamente.

Questo ragionamento viene usato come approccio in *Machine Learning*.

Esempio

REGOLA: "Socrate è un uomo."

CASO: "Socrate morì."

RISULTATO: "Tutti gli uomini sono mortali."

• Ragionamento Abduttivo: da ricondurre a *Peirce* (1839-1914). Qui il ragionamento viene invertito. Difatti viene ipotizziato che un'implicazione valga anche al contrario.

Esempio

REGOLA: "Tutti gli uomini sono mortali."

CASO: "Socrate morì."

RISULTATO: "Socrate è un uomo".

In *Machine Learning* si parte da dati osservati (casi base) per dedurre una regola (generalizzazione). Questo permette di:

- Descrivere i dati;
- Effettuare predizione sui nuovi casi che non ho ancora visto.

1.2 Che cosa è Machine Learning

Domande chiave per la Machine Learning:

- Quanto e perchè è utile un approccio basato su tecniche di Apprendimento Automatico;
- 2. Come si può apprendere;
- 3. Si può veramente apprendere.

Per iniziare a parlare di apprendimento è fondamentale trattare il concetto di algoritmo. Ovvero insieme finito di passi elementari sequenziali, che porta all'ottenimento di un risultato per risolvere un problema. L'algoritmo è un concetto fondamentale per l'informatica, in quanto permette di capire se un problema è calcolabile e rappresenta l'oggetto cardine durante lo sviluppo di un software (sviluppo di codice che permette la risoluzione effettiva di un problema da parte di un calcolatore).

Un esempio semplice di algoritmo è una ricetta di cucina composta da ingredienti e procedimento.

Tuttavia non sempre è possibile dare dei criteri oggettivi in modo da realizzare un algoritmo. Ipotizziamo di voler realizzare qualcosa che permette di individuare quali *e-mail*, che arrivano nella nostra casella di posta elettronica, sono SPAM. È possibile? E quali criteri di differenziazione dovrebbe controllare l'algoritmo? E se le *e-mail* a seguito di questa contromisura mutassero?. In conclusione non sempre si può risolvere un problema per mezzo du un algoritmo. I motivi per cui questo accade sono i seguenti:

- Impossibilità di formalizzare esattamente il problema;
- Rumore e/o incertezza nel input/output;
- Elevata complessità della soluzione;
- Inefficienza della soluzione;
- Si conosce solo il problema, ma non si sa come fare a risolverlo.

L'apprendimento, dal canto suo, è di primaria importanza, quando un sistema deve:

- Adattarsi all'ambiente in cui opera;
- Migliorare la propria performance nei confronti di un compito specifico;
- Scoprire regolarità e nuova conoscenza da dati empirici (ovvero non solo teorici, ma pratici).

I dati ormai sono abbondanti e presenti ovunque, questo ha permesso una crescita esponenziale della *Machine Learning*, specialmente durante l'ultimo ventennio. Con formalismo la *Machine Learning* è quella materia dove vengono studiati metodi per trasformare i dati in nuova conoscenza.

È importante per questo comprendere come esiste un processo stocastico (stato successivo non determinato dallo stato corrente, dove dunque è in auge la probabilità) che spiega i dati che osserviamo, anche se non nei dettagli; e come l'apprendimento sia in grado di costruire delle buone approssimazioni, utili, su questo processo.

L'obiettivo finale dell'apprendimento, e della *Machine Learning* in generale, è quello di definire dei criteri di *performance* e di ottimizzarli utilizzando l'esperienza pregressa o i dati. I modelli di apprendimento si suddividono in modelli Preattivi che effettuano previsioni sul futuro e Descrittivi, che invece, permettono di ottenere nuova conoscenza.

Vi sono numerosi esempi applicativi di *Machine Learning*. Il riconoscimento facciale, la *Named Entity Recognition* che permette d'identificare entità in un una frase, la classificazione dei documenti da un insieme di *topics*, i giochi e la profilazione del avversario, anche nel campo della bioinformatica per comprendere, per esempio, come reagirà un paziente a una certa terapia, e molti altri. Di nota è *Deep Blue* che nel 1997 è stata la prima macchina intelligente a riuscire a sconfiggere l'allora campione mondiale di scacchi, *Kasparov*; e *AphaGo* che nel 2016 riuscì a battere il campione di *Go Lee Sedal*.

Esistono anche le Generative Adversarial Learning che sulla base di immagini di training riescono a inventarsene di nuove. Questo dimostra come la Machine Learning può assumere un comportamento creativo. O ancora esiste un sistema composto da Rete generatrice e discriminante, in cui la prima deve riuscire a comprendere se le istanza sono create dalla Rete o da un essere umano e la seconda a crearne di verosimili.